

Predicción de metástasis ósea basada en perfiles de expresión genética para pacientes con cáncer de mama

Oswaldo Bueno Rivera

Centro de Investigación en Matemáticas, Guanajuato.

Ciencia de Datos.

25 de noviembre de 2025

Resumen

En este trabajo analizamos una base de datos de estudios de expresión genética correspondiente a pacientes con cáncer de mama, para quienes se conoce si desarrollaron metástasis ósea en los cinco años posteriores al diagnóstico. El objetivo principal es entrenar un modelo de clasificación capaz de predecir, a partir del perfil genético de una paciente, si se tendrá recurrencia en los huesos. De esta manera, buscamos construir una herramienta que pueda apoyar la identificación temprana de riesgo metastásico y, en consecuencia, facilitar la selección de tratamientos más específicos y personalizados.

1. Introducción

El cáncer de mama es una de las principales causas de mortalidad en mujeres a nivel mundial. A pesar de que una gran parte de las pacientes con cáncer de mama sin afectación ganglionar pueden curarse mediante tratamiento local o regional, un porcentaje significativo desarrolla metástasis ósea, incluso después de haber recibido tratamiento (este hecho se analiza en [Body et al. \(2017\)](#)). Lo anterior ha motivado la búsqueda de herramientas que permitan identificar dicha recurrencia desde etapas tempranas. Esto permitiría que las pacientes con mayor riesgo de presentar metástasis en el futuro puedan recibir tratamiento sistémico adyuvante, el cual se encarga de eliminar células cancerosas residuales que podrían causar una recurrencia o metástasis.

Debido a la gran frecuencia de la metástasis ósea en cáncer de mama, se han hecho esfuerzos a lo largo de los años para intentar comprender qué factores influyen en esto. Algunos estudios analizan factores de riesgo clínicos y patológicos, por ejemplo, [Li et al. \(2014\)](#) y [Liu et al. \(2021\)](#). Una alternativa que surge es considerar los perfi-

les de expresión genética para comprender mejor el cáncer y obtener predicciones más precisas.

En este trabajo analizamos la base de datos GSE2034 del GEO (Gene Expression Omnibus), el cual es un repositorio público de datos genómicos que forma parte del NCBI (National Center for Biotechnology Information). Estos datos se analizaron y publicaron por [Wang et al. \(2005\)](#), cuyo artículo tuvo como objetivo original identificar firmas moleculares capaces de predecir recurrencia. Este conjunto de datos contiene perfiles de expresión genética obtenidos mediante microarreglos de ADN en pacientes con cáncer de mama sin afectación ganglionar que no recibieron terapia adyuvante, y además nos proporciona la información de si una paciente tuvo metástasis ósea o no, al cabo de 5 años.

A partir de esta base de datos se llevó a cabo un análisis estadístico de la información genética de las pacientes, en el cual se integraron métodos de reducción de dimensionalidad y algoritmos de clasificación de aprendizaje supervisado. Nuestro objetivo es evaluar la capacidad predictiva

de estos algoritmos, buscando que en un futuro, estos puedan apoyar en decisiones clínicas más personalizadas.

2. Descripción de la base de datos.

El conjunto de datos GSE2034 que se encuentra público en el GEO contiene únicamente la información genética obtenida mediante microarreglos de ADN, ya que el resto de la información corresponde a datos de los autores o bien, se encuentra censurada. Cada medición corresponde al nivel de expresión de miles de genes en muestras de tejido tumoral de pacientes con cáncer de mama mediante intensidades de señal de ARN mensajero.

Dicho lo anterior, nosotros analizamos los niveles de expresión genética y la variable que nos hace saber si la paciente tuvo metástasis ósea en un lapso de 5 años.

El número de pacientes que se tiene es igual a 286, y para cada uno se tiene la medición del nivel de expresión de 22,283 genes en total. Es importante mencionar que este conjunto de datos no tiene valores vacíos, y en el artículo original no se hace mención de estos, por lo cual podemos asumir que contamos con datos completos y que no se llevó a cabo ninguna estrategia de limpieza de datos de antemano.

La variable binaria que nos proporciona la información acerca de si la paciente tuvo metástasis ósea cuenta con 217 valores iguales a 0 y 69 valores iguales a 1. Esto podemos visualizarlo en la Figura 1, donde el valor 0 representa que la paciente no tuvo metástasis ósea y el 1 que sí. Podemos observar que contamos con un desbalance de clases, lo que causará problemas a la hora de hacer las predicciones.

Además del desbalance de clases, contamos con un problema de alta dimensionalidad, ya que tenemos un total de 22,283 variables, por lo que, utilizar metodologías de reducción de dimensionalidad es crucial. Asimismo, el tener un número de muestras mucho menor que el número de co-




Figura 1. Distribución de la variable objetivo.

variables presenta un desafío.

3. Metodología.

3.1. Reducción de dimensionalidad

Antes de comenzar a emplear modelos o algoritmos de clasificación, primero haremos una reducción de dimensionalidad a nuestro problema para que nuestras predicciones sean más eficientes y mejores.

Dado el gran número de genes con el que contamos, empleamos el análisis de componentes principales (PCA), el cual permite capturar las principales direcciones de variabilidad biológica y reducir la influencia del ruido. Por supuesto, antes de llevar a cabo el PCA, primero se realizó una estandarización de las variables y se tomaron 45 componentes principales para la construcción de los nuevos datos reducidos (dicho valor se escogió probando un rango de 10 a 70 en busca de mejorar los resultados de los clasificadores). En la Figura 2 se presenta la gráfica de dispersión de nuestros datos en las dos primeras componentes principales, y podemos observar que estos se encuentran fuertemente mezclados. En la Figura 3 se muestra la varianza acumulada de las primeras 70 componentes

3.2. Empleo de modelos de clasificación

Una vez que tenemos los datos en las componentes principales separamos nuestros datos en conjuntos de entrenamiento y de validación, donde el tamaño del primero es el 70 % del conjunto de datos completo. Luego, llevamos a cabo el entrenamiento de distintos modelos de clasificación como Naive Bayes, Regresión Logística, Random Forest, k-NN (con parámetro $k = 5$), SVM y Redes Neuronales.

El Support Vector Machine (SVM) es un modelo supervisado de clasificación cuyo objetivo es encontrar un hiperplano óptimo que separe dos clases con el mayor margen posible.

Cuando los datos no son linealmente separables en el espacio original, SVM utiliza una técnica llamada kernel substitution, que consiste en proyectar los datos a un espacio de mayor dimensión donde sí puedan separarse linealmente, sin calcular explícitamente dicha transformación. Kernels comunes incluyen el lineal, polinomial y Radial Basis Function (RBF).

Dicho modelo de clasificación lo tomamos en cuenta debido a su popularidad en el área de estudios genéticos y que tiene un buen desempeño; por ejemplo, en [Feldes et al. \(2019\)](#), que es un repositorio de datos genéticos de pacientes con cáncer, puede observarse el gran desempeño de este clasificador.

Para más información sobre el algoritmo SVM puede verse el capítulo 7 de [Bishop and Nasrabadi \(2006\)](#).

Para la regresión logística y random forest cambiamos el umbral a través de la curva ROC, puesto que sin este cambio, dichos modelos clasificaban a todos los individuos como 0. Una vez hecho este ajuste se obtuvieron mejores resultados.

4. Resultados

En la Figura 4 presentamos el desempeño de los clasificadores considerados sobre el conjunto de validación, a través de las matrices de confusión. Dichas imágenes nos presentan un vistazo




Figura 2. Gráfica de dispersión de los datos reducidos en las dos primeras componentes principales.




Figura 3. Varianza acumulada en las primeras 70 componentes principales.

Modelo	Accuracy	Precision	Recall	F1
Naive Bayes	0.671 ± 0.090	0.401 ± 0.102	0.535 ± 0.128	0.443 ± 0.084
k-NN (k=5)	0.762 ± 0.024	0.403 ± 0.246	0.145 ± 0.101	0.212 ± 0.143
Regresión Logística	0.766 ± 0.035	0.617 ± 0.206	0.638 ± 0.285	0.538 ± 0.102
Random Forest	0.713 ± 0.059	0.468 ± 0.104	0.753 ± 0.118	0.562 ± 0.050
SVM	0.776 ± 0.044	0.551 ± 0.101	0.666 ± 0.076	0.592 ± 0.037
Red Neuronal	0.752 ± 0.026	0.493 ± 0.062	0.492 ± 0.121	0.483 ± 0.064

Cuadro 1. Resultados de validación cruzada.

de qué tan bien se están desempeñando los distintos modelos, y podemos ver que el SVM lo hace notablemente mejor que los demás, teniendo por detrás al Random Forest y la Red Neuronal. Sin embargo, esto no es suficiente para determinar qué tan bien están funcionando nuestros clasificadores ya que son los resultados de un único escenario. Por ello, llevamos a cabo validación cruzada dividiendo nuestros datos en 5 subconjuntos, y presentamos los resultados en el Cuadro 1.

En nuestros resultados de validación cruzada podemos observar que en general, el SVM y la regresión logística tienen las métricas más altas, pero la regresión logística cuenta con mucha varianza en algunos valores, lo cual indica que en ocasiones puede hacerlo muy bien y en otras muy mal.

5. Limitaciones del estudio

Este conjunto de datos presentó distintos problemas a lo largo de su estudio, y el principal es el gran número de genes de los que se tiene información. Al tener una base de datos de tan alta dimensión y con complejidad biológica tan fuerte, los datos resultan estar muy mezclados, y esto causa problemas.

El clasificador k-NN tuvo un desempeño muy pobre y esto puede deberse primeramente al desbalance de clases, y en segundo lugar al hecho de que los datos se encuentran muy mezclados, lo cual pudimos observar en la gráfica de dispersión sobre las primeras dos componente principales. Este modelo se intentó ajustar cambiando el umbral con la curva ROC y modificando el

parámetro k , pero nunca se obtuvieron mejoras.

Debido a lo mismo, es posible que el Naive Bayes no haya tenido tan buen desempeño como el SVM, pues este construye distribuciones gaussianas alrededor de los datos, y si estos siguen mezclados aún en altas dimensiones, es difícil que haga una buena clasificación.

Asimismo, es importante mencionar que la red neuronal tuvo un desempeño pobre en comparación al SVM o random forest. Para la red neuronal intentamos ajustar distintas funciones de activación y distinto número de capas, así como su tamaño; sin embargo, no fue posible mejorar su desempeño más allá. Esto nos muestra que las redes neuronales no siempre son el mejor modelo, y que tienen sus limitaciones.

De nuestros argumentos anteriores, tiene sentido que el SVM lo haya hecho bien, pues es un clasificador basado en kernels, lo cual hace que transforme los datos a otro espacio en el cual maximiza su separación bajo algún criterio, y entonces es ahí donde se realiza la clasificación.

Un último punto a tocar es el del PCA, cuya técnica escogimos debido a que fue la que nos mostró mejor desempeño al intentar reducir la dimensión de nuestro problema. Bajo el razonamiento de que el SVM funciona bien, intentamos emplear el kernel PCA (ver sección 12.3 de [Bishop and Nasrabadi \(2006\)](#)), pero bajo esta transformación de los datos no obtuvimos mejoría en las clasificaciones. Esto nos muestra una vez más como la gran dimensión y naturaleza de nuestros datos es un problema fuerte.




Figura 4. Matrices de confusión de los modelos de clasificación sobre el conjunto de validación.

6. Conclusiones

A partir de los resultados obtenidos tanto en las matrices de confusión como en la validación cruzada, podemos concluir que el modelo SVM (con kernel RBF) fue el algoritmo con mejor desempeño en la predicción de metástasis ósea en pacientes con cáncer de mama. En particular, mostró el valor más alto de puntaje F1 y de los valores más altos en las demás métricas, todos ellos con varianzas aceptables, lo cual indica que logra identificar con mayor eficacia a las pacientes que realmente desarrollarán metástasis.

No obstante, su precisión cercana a 0.55 evidencia que, entre los casos que el modelo clasifica como positivos únicamente alrededor de la mitad corresponde efectivamente a pacientes que desarrollarán metástasis ósea. Este comportamiento sugiere que, aunque el SVM es el mejor entre los modelos comparados, su utilidad clínica sería limitada si se emplea como único criterio de decisión. En un escenario real, este tipo de sistema debería integrarse con otros factores para mejorar la confiabilidad de la predicción.

El cáncer de mama, al igual que la mayoría de las enfermedades oncológicas, presenta una complejidad biológica considerable, y resulta difícil capturarla completamente mediante la expresión genética medida por microarreglos; por ello, no es sorprendente que los modelos de clasificación no alcancen desempeños muy altos. Aun así, los resultados obtenidos no son despreciables y muestran que existen patrones en los datos genómicos que pueden apoyar la identificación temprana de pacientes con riesgo de desarrollar metástasis ósea.

En resumen, aunque el desempeño predictivo es moderado, el análisis realizado demuestra que los modelos de clasificación supervisada aplicados a datos genómicos pueden aportar información relevante para el entendimiento del riesgo a desarrollar metástasis ósea, y así poder efectuar tratamientos más específicos en las pacientes identificadas.

7. Trabajo futuro

En el presente trabajo pudimos observar que el clasificador SVM logra un desempeño moderadamente bueno de las pacientes que tienen metástasis ósea dentro del conjunto de entrenamiento. Así, una pregunta natural que surge es cómo funcionaría nuestro modelo entrenado, con datos que provengan de otros proyectos independientes, y si es que alguno de los otros modelos lo haría mejor. Dicho estudio podría llevarse a cabo gracias al gran número de datos que contiene el GEO.

De la misma manera, resulta relevante estudiar si el SVM tendría un desempeño similar, o mejor, al analizar otros tipos de cáncer para los cuales exista información de recurrencias óseas. Este tipo de investigación también sería factible con una búsqueda cuidadosa dentro del GEO u otros repositorios públicos, lo que abriría la puerta a comparar la utilidad del modelo en diversos contextos biológicos.

Referencias

- Bishop, C. M. and Nasrabadi, N. M. (2006). *Pattern recognition and machine learning*, volume 4. Springer.
- Body, J.-J., Quinn, G., Talbot, S., Booth, E., Demonty, G., Taylor, A., and Amelio, J. (2017). Systematic review and meta-analysis on the proportion of patients with breast cancer who develop bone metastases. *Critical reviews in oncology/hematology*, 115:67–80.
- Feltes, B., Chandelier, E. B., Grisci, B. I., and Dorn, M. (2019). Cumida: An extensively curated microarray database for benchmarking and testing of machine learning approaches in cancer research. *Journal of Computational Biology*, 26(4):376–386.
- Li, B. T., Wong, M. H., and Pavlakis, N. (2014). Treatment and prevention of bone metastases from breast cancer: a comprehensive review of evidence for clinical practice. *Journal of clinical medicine*, 3(1):1–24.

Liu, H., Zhang, X., Zhang, S., Wang, X., and Yu, S. (2021). Factors associated with bone metastasis in breast cancer: A systematic review and meta-analysis. *Annals of Palliative Medicine*, 10(4):4435452–4434452.

Wang, Y., Klijn, J. G., Zhang, Y., Sieuwerts, A. M., Look, M. P., Yang, F., Talantov, D., Timmermans, M., Meijer-van Gelder, M. E., Yu, J., et al. (2005). Gene-expression profiles to predict distant metastasis of lymph-node-negative primary breast cancer. *The Lancet*, 365(9460):671–679.